2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 23

Pezzati, Tomás

Garrido, Mateo

Fredes, Rafael

1. Introducción

1.1 Contexto y Espacio del Problema

La industria del desarrollo de software atraviesa una transformación marcada por la volatilidad económica global, el reordenamiento de los esquemas de trabajo remoto, híbrido y presencial, una disparidad salarial fuerte entre regiones y la irrupción de la inteligencia artificial generativa y de los agentes autónomos de código.

Comprender esas dinámicas exige tres preguntas. La primera es hasta qué punto la experiencia profesional determina la confianza frente a las respuestas generadas por la inteligencia artificial. La segunda es si, a igual formación académica y años programando, persiste una brecha salarial entre quienes residen en América Latina y quienes residen en el resto del mundo. La tercera es cómo se vincula la satisfacción con los distintos aspectos del trabajo con la propensión a cambiar de rol o de industria. El estudio responde la primera y la tercera con métodos estadísticos sobre esta encuesta. La comparación de ingresos que se estima es la de quienes respondieron desde Argentina frente al triple del salario mínimo, vital y móvil.

Comprender empíricamente de qué manera interactúan estas variables con la experiencia, la satisfacción y la compensación de los profesionales resulta indispensable para dimensionar la realidad laboral del sector y fundamentar decisiones estratégicas en un entorno de alta incertidumbre tecnológica.

1.2 El Conjunto de Datos: Origen, Investigaciones y Utilidad Práctica

El estudio usa los datos primarios de la Stack Overflow Developer Survey 2025, el relevamiento anual de la comunidad global de desarrollo de software. A partir de la investigación en internet, se constató que la recolección se administró mediante Qualtrics (cuyo formulario oficial se detalla en el instrumento de relevamiento) y los datos fueron obtenidos desde el repositorio público oficial en GitHub de Stack Exchange y su réplica en Kaggle. La base reúne 49.191 respuestas de profesionales y estudiantes de 177 países y 172 atributos, agrupados en situación laboral, compensación económica, stack tecnológico, comunidad y adopción de herramientas de inteligencia artificial.

Esa cobertura sirve a quien conduce equipos, a quien investiga la formación en la industria y a quien trabaja en ella. Permite armar referencias salariales, mirar qué pesa en la atracción y en la retención, y ver cómo se integran las herramientas de

inteligencia artificial. También deja evidencia sobre trayectorias de aprendizaje, sobre la evolución de los lenguajes y sobre el alcance de la educación formal, y ofrece una lectura pública de expectativas salariales, modalidades de trabajo y tecnologías demandadas.

1.3 Desafíos e Inconsistencias Detectadas en los Datos y Estrategia de Corrección

La inspección de los datos crudos mostró problemas de estructura. El CSV trae 172 columnas, muchas nacidas de preguntas matriciales (*WorkedWith*, *WantToWorkWith*, *Admired*), con un costo alto y con riesgo de dispersar el análisis. En las nueve columnas con sufijo *Admired*, el valor coincide con la intersección entre las tecnologías usadas el último año y las que se quieren usar el año siguiente, de modo que la columna repite información ya presente en las otras dos. Cerca de 25 columnas de texto libre, con sufijos *TEXT*, *Entry* o *Write*, superan el 92 % de faltantes y mezclan comentarios sueltos con variantes de escritura. Gran parte de los nulos no proviene de un error de carga. El cuestionario bifurca, y los bloques de inteligencia artificial solo piden respuesta a quien usa esas herramientas. En *CompTotal* y *ConvertedCompYearly* se mezclan pesos y dólares, y aparecen ingresos declarados atípicos.

La corrección siguió esa lectura. Se descartaron las columnas *Admired* y las de texto libre, sin perder la información cuantitativa que ya estaba en las variables de uso y de preferencia. No se aplicó un umbral ciego de nulos: el faltante estructural se conserva, y cada hipótesis trabaja con la población a la que la pregunta alcanza. Las variables seleccionadas son las que conforman **df_interes**. El ranking **JobSatPoints_**, que la hipótesis de cambio de rol necesita en sus quince puestos, se preservó dentro de las 46 variables de **df_interes**, manteniendo las columnas originales sin binarizar para alimentar directamente la regresión logística. En los salarios de Argentina, el monto mensual es **ConvertedCompYearly** dividido 12, en dólares. La cota de tres salarios mínimos, vitales y móviles se expresa en esa misma unidad con la tasa implícita de Stack Overflow, 1.172,26 pesos por dólar, y se apartan los registros con ingresos exorbitantes o sin paga.

Para corregir estas inconsistencias sin perder información crítica, se implementó una estrategia en cuatro fases: 1. Selección de variables **df_interes**: se aisló un subconjunto de 46 columnas clave, descartando columnas de texto libre y matrices duplicadas 2. Estandarización de ausentes: se convirtieron los valores textuales **NA** al objeto nativo **pd.NA** de Pandas 3. Preservación por ramificación: se evitó el descarte ciego de columnas con alto porcentaje de nulos, protegiendo variables esenciales como **JobSat** o **CompTotal** cuyos vacíos responden a la lógica del formulario 4.

Normalización salarial y outliers: se auditaron las monedas locales y se acotaron los ingresos en **ConvertedCompYearly** a un rango verosímil ($300 a $900.000 USD anuales) para garantizar la robustez de los contrastes estadísticos posteriores.

1.4 Organización del Trabajo y Estructura del Informe

El resto del informe sigue ese recorrido. La sección 2 presenta el análisis exploratorio y la preparación de los datos: los criterios con los que se eligieron las variables de **df_interes** y los tipos de datos. La sección 3 desarrolla las hipótesis de la cátedra y las del equipo, y en cada una fija la población y revisa los supuestos. El salario en Argentina, a partir de **Country**, **Currency**, **CompTotal** y **ConvertedCompYearly**, se contrasta con Wilcoxon de rangos con signo después de un Shapiro-Wilk. La experiencia y la confianza en la inteligencia artificial, con **WorkExp** y **AIAcc**, se contrastan con Kruskal-Wallis, y Levene se usa para leer la dispersión. La satisfacción y el cambio de rol, con **NewRole** y los puestos **JobSatPoints**, se modelan con una regresión logística. La hipótesis univariada analiza la distribución y equidad de las modalidades de trabajo (**RemoteWork**), mientras que la bivariada evalúa la asociación entre el tamaño de la organización (**OrgSize**) y el uso de agentes autónomos (**AIAgents**) mediante una prueba de independencia Chi-cuadrado. Los perfiles de trayectoria y herramientas, con **WorkExp**, **YearsCode**, **ToolCountWork** y **ToolCountPersonal**, se arman con componentes principales y K-means, y la satisfacción de esos perfiles (**JobSat**) se contrasta de nuevo con Kruskal-Wallis. La sección 4 cierra con las conclusiones de esos contrastes.

2. Análisis exploratorio de los datos

2.1. Caracterización inicial y dimensionalidad

El análisis parte de la base cruda proporcionada por la encuesta global Stack Overflow Developer Survey 2025 (**stackOverflow_survey_2025_results_public.csv**), cuya recolección fue administrada a través de la plataforma Qualtrics. Al importar el conjunto de datos y examinar su estructura mediante **df_encuestas.info()**, se constata una dimensión inicial de **49.191 observaciones (filas) y 172 variables (columnas)**. Cada registro individual modela las respuestas brindadas por una persona encuestada (desarrolladores profesionales, estudiantes y aficionados al código de 177 países). (Notebook: Sección "Análisis inicial", bloque de inspección inicial df_encuestas.info() y schema_encuestas)

A partir del archivo de metadatos **esquema_stack_overflow.csv** y del cuestionario oficial (**2025_Developer_Survey_Tool.pdf**), se identificó que las 172 columnas del dataset no responden a una correspondencia biunívoca simple con las preguntas del formulario. Por el contrario, se derivan de cuatro tipos estructurales de preguntas implementadas en Qualtrics:

- **Opción múltiple (Multiple Choice - MC):** Preguntas de selección única o múltiple; en este último caso, las alternativas seleccionadas se almacenan dentro de una misma celda como cadenas de texto delimitadas por punto y coma (;), requiriendo parsing específico para aislar componentes.
- **Entrada de texto libre (Text Entry - TE):** Respuestas abiertas numéricas o textuales (por ejemplo, años de trayectoria o conteo de herramientas).
- **Ordenamiento de preferencias (Rank Order - RO):** Preguntas donde el encuestado ordena un conjunto de elementos según su importancia (asignando valores enteros donde 1 representa la máxima prioridad). En el archivo tabular, cada ítem evaluado se descompone en una columna independiente (por ejemplo, la batería **JobSatPoints_1** a **JobSatPoints_16**).
- **Grillas o matrices (Matrix):** Preguntas multidimensionales cruzadas (como tecnologías con las que trabajó en el último año frente a las que desea trabajar el próximo año), las cuales se expanden en múltiples columnas en formato ancho.

Diagnóstico preliminar de datos faltantes y missing estructural

La exploración cuantitativa arrojó un volumen significativo de valores ausentes representados analíticamente por la cadena de texto **"NA"** o el objeto nativo **pd.NA**. Una práctica ingenua y desaconsejada en la literatura de la ciencia de datos consiste

en aplicar un umbral de corte global ciego (por ejemplo, descartar automáticamente cualquier columna con más de un 40% o 50% de valores nulos).

Un análisis estructural de la encuesta nos demostró que la gran mayoría de estos datos no corresponden a pérdidas aleatorias, sino a un **mecanismo de ausencia estructural condicional debido a saltos lógicos por bifurcación en el cuestionario**. En el diseño de Qualtrics, las secciones subsiguientes se condicionan a las respuestas de filtrado: quienes indicaron no utilizar herramientas de Inteligencia Artificial saltan por completo el bloque detallado de confianza y herramientas de agentes; asimismo, las preguntas de satisfacción laboral (**JobSat**, con un 45,8% de nulos en crudo) y de salario anual (**CompTotal**, con un 49,5% de nulos) solo fueron exhibidas a quienes declararon estar empleados o desempeñarse profesionalmente. Aplicar un descarte automático por porcentaje de nulos habría eliminado variables vertebrales para las hipótesis del trabajo. En consecuencia, se determinó preservar los faltantes estructurales en esta fase y definir la población analítica de forma segmentada según los requerimientos de cada contraste.

2.2. Selección del subconjunto de variables de interés (**df_interes**)

Para optimizar el costo computacional y enfocar el estudio sin dispersión ni pérdida de información estadística sustantiva, se aplicaron criterios metodológicos rigurosos de reducción horizontal documentados en el análisis del grupo:

- **Eliminación de columnas redundantes (Admired):** Las 9 columnas con el sufijo ***Admired** (como **LanguageAdmired** o **AIModelsAdmired**) fueron eliminadas. Se constató formalmente que en las 49.191 filas sus valores coinciden exactamente con la intersección lógica entre **HaveWorkedWith** (uso en el último año) y **WantToWorkWith** (deseo de uso futuro). Conservarlas no aportaba variabilidad adicional y duplicaba información.
- **Exclusión de campos de texto libre no estructurado (_TEXT, Entry, Write):** Se apartaron las 29 columnas clasificadas formalmente como TE (texto libre) y rescatamos solo 5 de ellas (**WorkExp**, **YearsCode**, **ToolCountWork**, **ToolCountPersonal** y **CompTotal**), sustanciales para las hipótesis . En el esquema que exhiben entre un 92% y un 99,5% de registros nulos y una cardinalidad desmedida (errores tipográficos, comentarios aislados), cuyo procesamiento mediante PLN no se justificaba para los objetivos estadísticos del proyecto.

  (Notebook: Sección "Análisis inicial", celda 'schema_encuestas.loc[schema_encuestas["type"] == "TE"]')

- **Preservación del núcleo de inferencia:** Se construyó el subconjunto **df_interes** asegurando algunas variables demográficas de perfil (**Country**, **Age**, **EdLevel**, **MainBranch**, **Employment**, **RemoteWork**, **OrgSize**), los bloques de compensación (**Currency**, **CompTotal**, **ConvertedCompYearly**), las métricas de trayectoria y satisfacción (**WorkExp**, **YearsCode**, **JobSat**, **NewRole**, y el ranking **JobSatPoints_***), y las dimensiones tecnológicas y de IA (**AISelect**, **AIAcc**, **AIAgents**, y los bloques ***HaveWorkedWith**). En la notebook ejecutada se consolidó **df_interes** en 46 columnas seleccionadas.

Referencia de código en la notebook: Sección “Análisis inicial” → bloque de filtrado de variables

2.2.1. Advertencias y anomalías detectadas en el **describe()**

Al aplicar el método estadístico descriptivo **df_interes[cols_cuant].describe()** sobre los atributos cuantitativos (**WorkExp**, **YearsCode**, **ToolCountWork**, **ToolCountPersonal**, **CompTotal**, **ConvertedCompYearly**), surgieron alertas críticas respecto a la validez de los datos crudos:

1. **Valores biológicamente y laboralmente imposibles:** Tanto en años de experiencia profesional (**WorkExp**) como en años totales programando (**YearsCode**), los valores máximos alcanzaron los 100 años.
2. **Conteos desorbitantes de herramientas:** La variable **ToolCountWork** (cantidad de herramientas empleadas en el trabajo) registró un máximo inverosímil de 10.000 herramientas, mientras que **ToolCountPersonal** alcanzó un máximo de 1.000, contrastando con medianas muestrales de 6 y 5 herramientas respectivamente.
3. **Inconsistencias y asimetría extrema en compensación económica:** Se hallaron valores de compensación anual convertida (**ConvertedCompYearly**) de tan solo 1 USD (y en salarios mensuales calculados para Argentina montos de 0,83 USD), junto con montos astronómicos de hasta 50.000.000 USD anuales. Estas distorsiones derivan de errores de carga del encuestado (declaración mensual en lugar de anual, confusión de divisas o respuestas jocosas). En la notebook se auditó este fenómeno, identificando registros por debajo del piso analítico de 300 USD y por encima de 900.000 USD anuales, los cuales requirieron acotamiento y enmascaramiento como **pd.NA** para no sesgar las inferencias posteriores.

2.3. Exploración de distribuciones y patrones clave

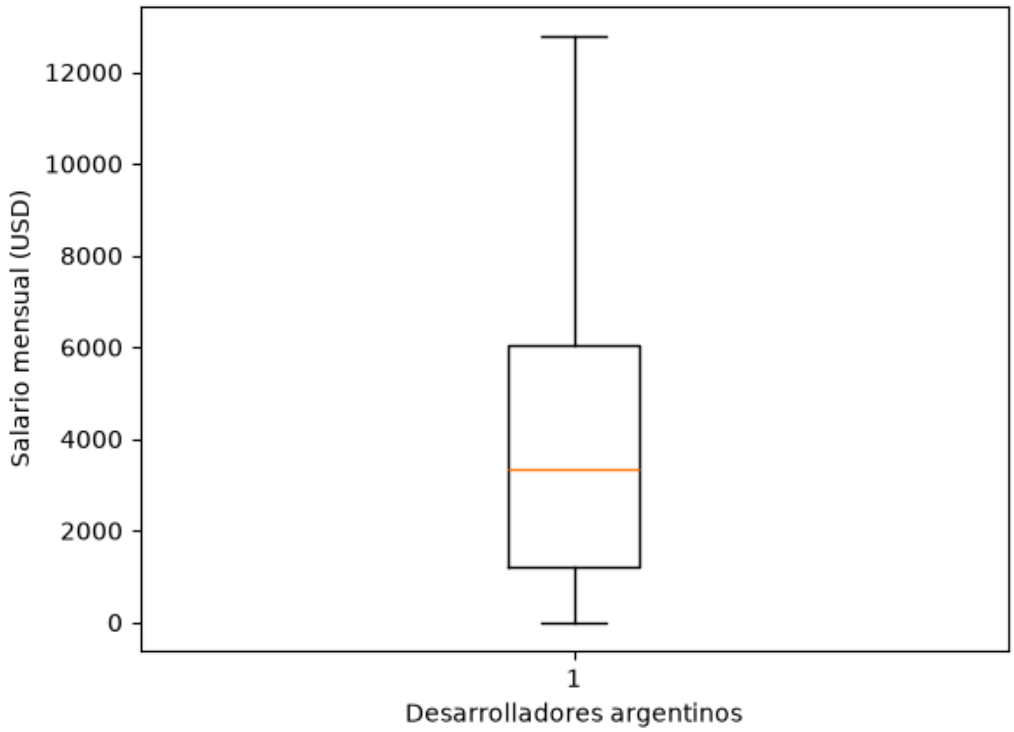
A continuación se analizan los comportamientos empíricos de las variables críticas a través de las visualizaciones generadas por el grupo en la notebook de trabajo.

2.3.1. Distribución del salario mensual en Argentina

En el análisis univariado preliminar de la compensación de los desarrolladores residentes en Argentina (Country == "Argentina", 222 respuestas en total), se construyó la variable **Salario_Mensual_USD** dividiendo **ConvertedCompYearly** por 12. De las 222 observaciones, 160 informaron salarios válidos.

El gráfico de caja correspondiente (boxplot) evidencia una marcada asimetría positiva (sesgo hacia la derecha), con una mediana de 3.333,33 USD mensuales, un rango intercuartílico situado entre 1.204 USD (Q1) y 6.052 (Q3), y una media de 3.855,93 USD inflada por la presencia de valores atípicos superiores que alcanzan los 12.795,83 USD.

Esta marcada asimetría fue corroborada analíticamente, a través de una prueba en el chequeo de hipótesis, sobre la normalidad de dicha distribución. Mediante un Test de Shapiro-Wilk , se rechazó la normalidad y se descartó el uso de pruebas paramétricas como el test t de Student.



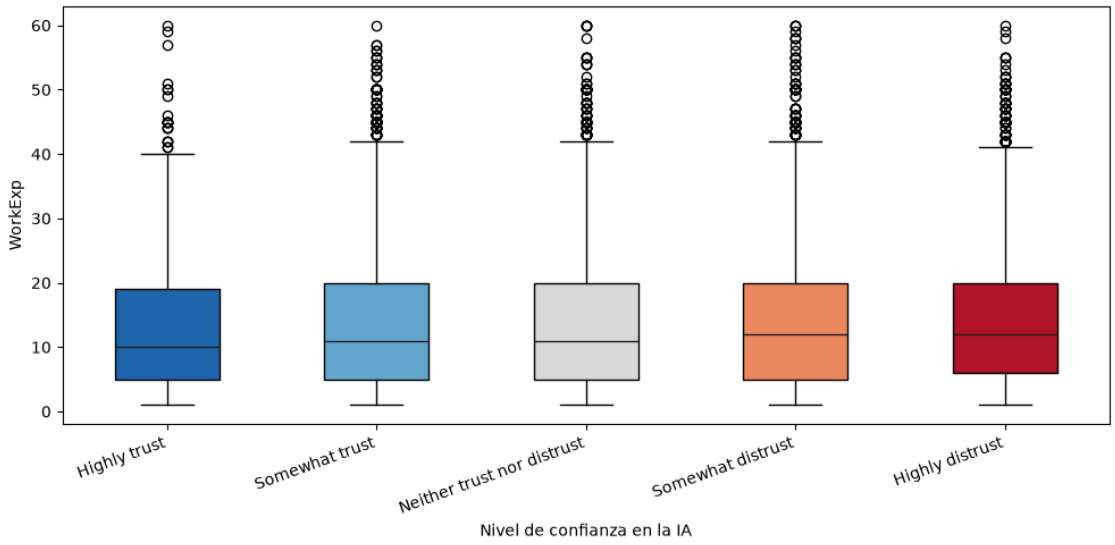
- **Fig. 1:** Distribución del salario mensual en USD para desarrolladores en Argentina (n = 160). Se observa una notable asimetría a la derecha, con mediana en 3.333,33 USD y valores atípicos que se extienden hasta los 12.795,83 USD.

(Notebook: Sección "CATEDRA — limpieza de una copia", celda de cálculo y boxplot de Salario_Mensual_USD)

2.3.2. Experiencia laboral según niveles de confianza en la IA

Al cruzar los años de experiencia profesional (**WorkExp**) en función de los cinco niveles ordenados de confianza en las herramientas de IA (**AIAcc**: *Highly trust*, *Somewhat trust*, *Neither trust nor distrust*, *Somewhat distrust*, *Highly distrust*), se generaron diagramas de cajas agrupados.

Visualmente, las medianas de experiencia laboral entre los cinco grupos se ubican en valores muy cercanos (en torno a los 11 y 13 años). No obstante, el diagrama revela variaciones en la dispersión interna y colas de valores atípicos superiores. Al someter las varianzas muestrales al test de Levene, se obtuvo un estadístico de 6,8038 (p - valor = 1,807 x 10 ^ -5), lo que comprueba formalmente la existencia de heterocedasticidad (las varianzas no son homogéneas entre niveles de confianza).



- **Fig. 2:** Comparación de la experiencia profesional (**WorkExp**) a través de los cinco niveles de confianza en la IA (**AIAcc**). Las medianas resultan visualmente homogéneas, pero exhiben heterocedasticidad significativa (p < 0,001).

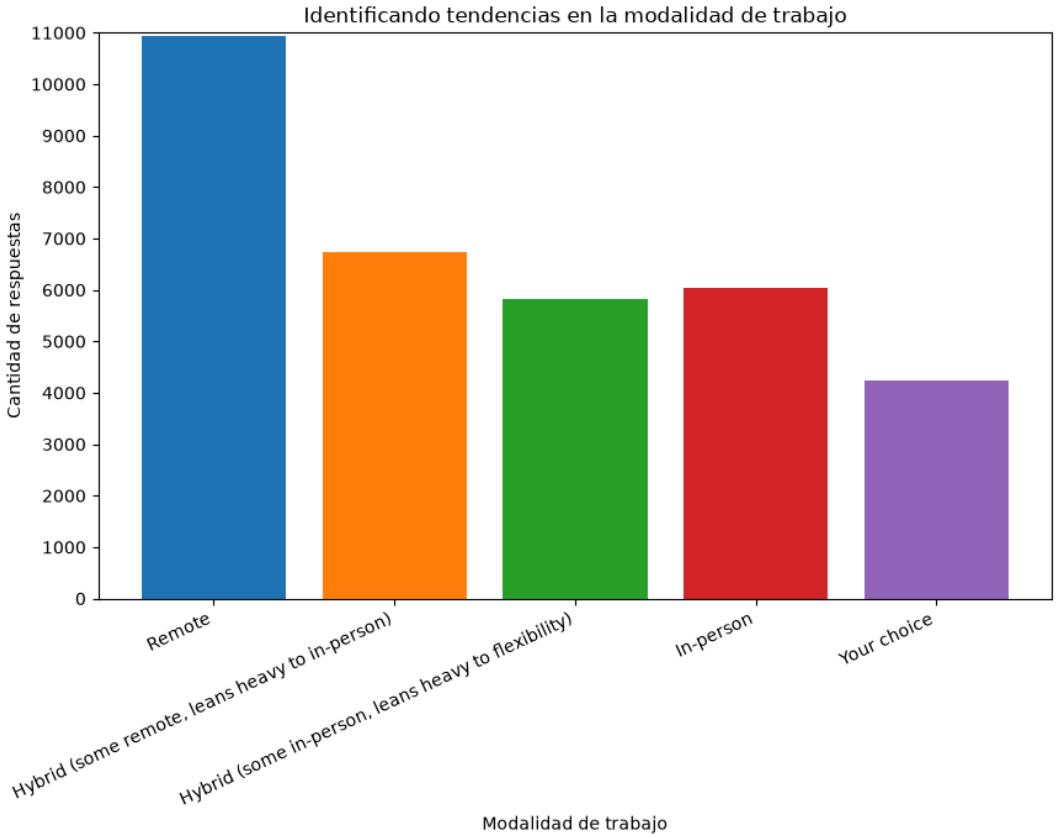
  (Notebook: Sección "Hipótesis 2", bloque de boxplot agrupado y prueba de Levene)

2.3.3. Distribución y disparidad en las modalidades de trabajo

La exploración de la variable categórica **RemoteWork** arrojó 33.780 casos con respuesta válida. Al computar sus frecuencias absolutas mediante un diagrama de

barras ordenado, se comprueba una pronunciada asimetría en las preferencias laborales del sector:

- **Modalidad remota (Remote):** 10.931 encuestados.
- **Híbrido con sesgo presencial:** 6.732 encuestados.
- **Completamente presencial (In-person):** 6.042 encuestados.
- **Híbrido con sesgo flexible:** 5.831 encuestados.
- **Elección libre del desarrollador (Your choice):** 4.244 encuestados.



- **Fig. 3:** Frecuencia absoluta por modalidad de trabajo. Se evidencia un predominio categórico del trabajo puramente remoto (10.931 casos).

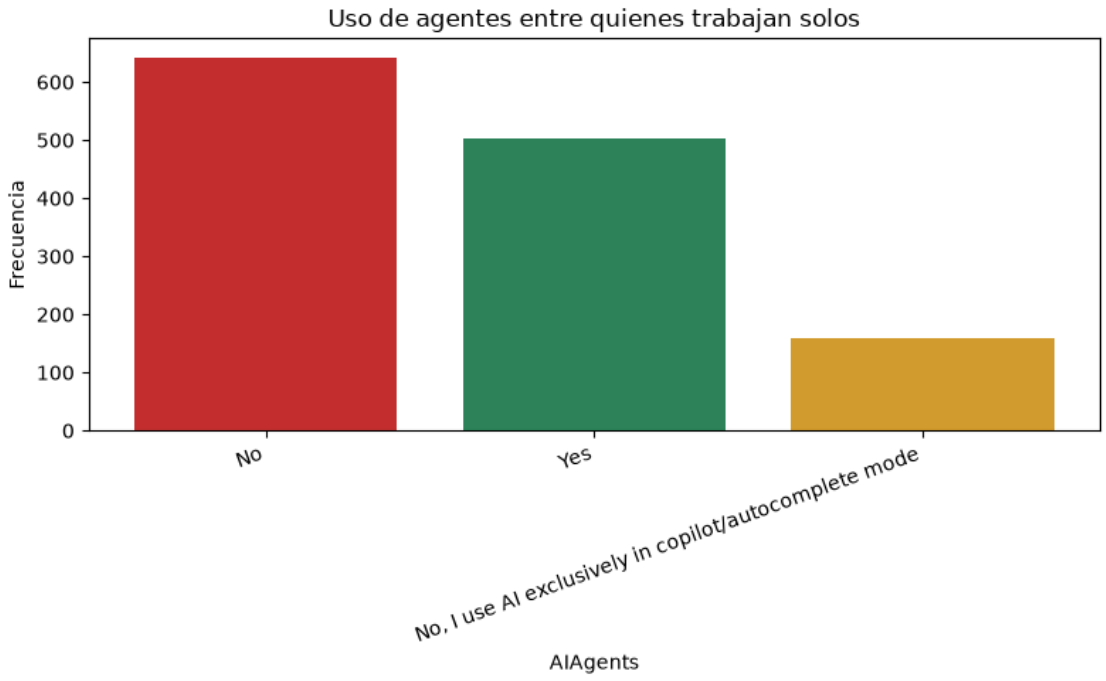
  (Notebook: Sección "HIPOTESIS - Grupo 23", apartado "H1: La modalidad de trabajo", gráfico de barras ordenado)

2.3.4. Adopción de agentes de IA y tamaño de la organización

Al analizar la relación bivariada entre la dimensión de la empresa (**OrgSize**) y la adopción de agentes autónomos (**AIAgents**), se exploró en primera instancia el subconjunto de encuestados independientes (freelancers, OrgSize == "Just me...")

bajo la hipótesis intuitiva de que el trabajador solitario supliría la falta de estructura contratando o adoptando más agentes.

El gráfico de barras correspondiente a este segmento desmintió la intuición preliminar: la categoría de no adopción ("No", agrupando quienes no planean usarlos o planean hacerlo a futuro) alcanzó 643 respuestas, superando ampliamente a los usuarios activos de agentes ("Yes", 503 respuestas) y a los usuarios exclusivos de copilotos/autocompletado (158 respuestas).



- **Fig. 4:** Adopción de agentes de IA en trabajadores independientes. Contrario a la hipótesis intuitiva, prevalece la respuesta negativa ("No", 643 casos) sobre la adopción activa ("Yes", 503 casos).

  (Notebook: Sección "HIPOTESIS - Grupo 23", apartado "H2: El tamaño de la organizacion/empleador está asociado con el uso de agentes de IA", celda de gráfico de barras para OrgSize == freelancer)

2.3.5. Análisis multidimensional de trayectoria, herramientas y satisfacción (JobSat)

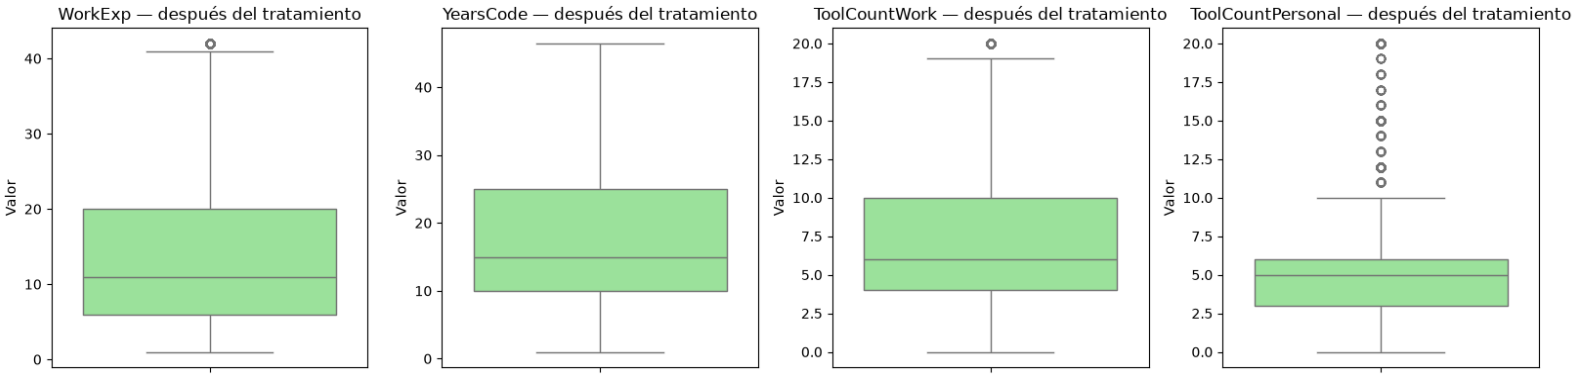
Para el análisis multivariado de perfiles, se examinaron conjuntamente cuatro predictores continuos/discretos de trayectoria y recursos técnicos (**WorkExp**, **YearsCode**, **ToolCountWork**, **ToolCountPersonal**) en una población filtrada de desarrolladores profesionales empleados de 34.146 casos (con 17.756 registros completos en las 4 variables).

- **Inspección y corrección de outliers:** La cuadrícula de boxplots iniciales evidenció valores extremos severos en el conteo de herramientas. **Para este análisis multivariado**, en la notebook se procedió a mitigar el impacto aplicando un recorte superior al percentil 99 (P99) en **WorkExp** y **YearsCode**, e imputando por la mediana aquellos valores que excedían estrictamente el percentil 95 (P95) en **ToolCountWork** y **ToolCountPersonal** (dejando intacto **df_interes** para el resto de los análisis).

  (Notebook: Sección "Hipótesis 3: Perfiles de trayectoria, herramientas y satisfacción laboral", bloque "Tratamiento de outliers")

- **Distribución de la satisfacción laboral (JobSat):** Al inspeccionar **JobSat** (escala discreta de 0 a 10) sobre las 17.147 observaciones válidas, se identificó una fuerte asimetría negativa o sesgo hacia puntuaciones altas. La moda se ubica claramente en 8 puntos, y más del 85% de las respuestas son estrictamente superiores a 5, concentrándose la gran masa de datos en percepciones laborales favorables.

  (Notebook: Sección "Hipótesis 3: Perfiles de trayectoria, herramientas y satisfacción laboral", celda de gráfico de barras 'Distribución de satisfacción laboral (JobSat)')



- **Fig. 5:** Distribución de frecuencias de satisfacción laboral (**JobSat**, escala 0–10, n = 17.147). Se evidencia una marcada asimetría negativa (sesgo hacia la izquierda / masa acumulada a la derecha), con moda en 8 y más del 85% de las respuestas superiores a 5.

2.4. Puente hacia las hipótesis y formulación de contrastes

Los hallazgos derivados del análisis exploratorio fundamentaron de manera directa las decisiones metodológicas adoptadas en la Sección 3 para cada contraste estadístico:

1. **Motivación de pruebas no paramétricas para el salario en Argentina:** La marcada asimetría positiva en **Salario_Mensual_USD** y el rechazo concluyente de normalidad en Shapiro-Wilk ($W = 0{,}9003$; $p < 0{,}001$) impidieron el uso del test t de Student. Esto motivó formular el contraste univariado frente a la cota del SMVM (tres veces el salario mínimo, equivalente a 980,38 USD) mediante la prueba de rangos con signo de Wilcoxon para una muestra.
2. **Abordaje no paramétrico y de varianza para la experiencia y la IA:** La inspección gráfica de **WorkExp** según los niveles de **AIAcc** y la confirmación de varianzas heterogéneas mediante la prueba de Levene ($p < 0{,}001$) justificaron el uso del test de Kruskal-Wallis, evaluando si las diferencias de trayectoria implican un cambio genuino en la distribución de la confianza en modelos generativos.
3. **Modelado multivariado de satisfacción y cambio de carrera:** El análisis del ranking ordinal completo de 15 ítems (**JobSatPoints_***) y su relación con la variable nominal **NewRole** reveló que el puntaje global de satisfacción (**JobSat**) no permitía discriminar qué dimensiones específicas empujan al cambio laboral. Esto motivó depurar una muestra estricta de 24.729 casos con permutaciones completas de rangos para ajustar un modelo de regresión logística (multinomial / binaria), aislando predictores clave como calidad, mentoreo y estabilidad.
4. **Contrastes de frecuencias e independencia para organización y trabajo:** Las disparidades visuales halladas en los gráficos de barras motivaron el planteo de contrastes categóricos formales: una prueba de bondad de ajuste chi-cuadrado para contrastar la equidad de las modalidades de trabajo (**RemoteWork**), y una prueba chi-cuadrado de independencia con cálculo de la V de Cramér entre el tamaño de la firma (**OrgSize**) y la adopción de agentes (**AIAgents**).
5. **Reducción de dimensionalidad y agrupamiento:** La correlación entre experiencia laboral y años de código, sumada a la dispersión de herramientas técnicas, sentó la necesidad de aplicar un Análisis de Componentes Principales (PCA) y K-Means clustering, comprobando una varianza explicada acumulada superior al 83% en los dos primeros componentes para caracterizar perfiles técnicos objetivos.

3. Hipótesis y resolución

3.1. Hipótesis 1:

3.1.1. Definición de la hipótesis

Abordamos la hipótesis de la cátedra: “Los desarrolladores que respondieron la encuesta en Argentina tienen un salario tres veces mayor que el Salario Mínimo, Vital y Móvil (SMVM)”.

Con ella evaluamos a quienes respondieron desde Argentina y situamos los perfiles de IT, tecnología y desarrollo de software frente a un parámetro nacional. El contraste nos sirve para describir la situación del sector y para comparar un sueldo individual con ese umbral.

Al 1/9/2026 el SMVM es de $383.000 y el triple es $1.149.000, dicho valor se encuentra en pesos y lo tomamos del Ministerio de Capital Humano de la Nación Argentina (https://www.argentina.gob.ar/trabajo/consejodelsalario).

Resulta de sumo interés para

3.1.2. Estrategia de abordaje

Trabajamos con las 222 respuestas de **Country** = Argentina. El contraste es univariado, tomando el salario mensual frente a la cota de 3 × SMVM.

Dado a que no todos los datos se encuentran en la misma moneda en **CompTotal**, se recurre a considerar **ConvertedCompYearly**(en USD para todos). Adicionalmente construimos una cotización propia USD/ARS para la conversión del SMVM, porque al investigar esas fechas, encontramos fluctuaciones significativas en el tipo de cambio oficial.
 El salario mensual es **ConvertedCompYearly** / 12. Con esa cotización, de aproximadamente 1.172 ARS por USD, la cota queda en:
1.149.000 (el monto en pesos) / 1.172 ≈ 980,38 USD.

Filtramos registros probablemente corruptos que declaraban salarios exorbitantes, y también registros nulos(NaN), no así en el caso de quienes tenían valor 0$; en este caso, consideramos posible la existencia de desarrolladores juniors que trabajan ad donorem o aún no han sido remunerados por su trabajo.
Imputamos por la mediana los salarios mensuales faltantes (3.333,33 USD), bajo el objetivo de mantener la distribución para 222 muestras.

Para la media habríamos usado un test t de Student si el salario verificase el test de normalidad, dado que era cuantitativo continuo, las respuestas eran independientes, pero al efectuar un Test de Shapiro sobre las observaciones:
$W = 0{,}9003$ y $p = 5{,}385 \times 10^{-11}$. **Rechazamos la normalidad**

Aplicamos entonces Wilcoxon, alternativa no paramétrica sobre la mediana que evalúa los rangos con signo para una muestra, unilateral:

- H0: la mediana del salario mensual es mayor o igual que 3 × SMVM.
- H1: la mediana es menor que esa cota.

Estos cálculos están en el apartado «Hipótesis 1» de la notebook.

3.1.3. Resultados obtenidos y discusión

Sobre las 222 observaciones, después de imputar por la mediana, obtenemos :
$W = 23.712$ y $p = 1{,}000$. El p-valor supera 0,05 y mantenemos H0.

No encontramos evidencia estadística de que la mediana del salario mensual (USD) sea inferior a la cota de 3 × SMVM (aproximadamente 980 USD). Los datos son compatibles con que la mayoría de quienes declararon compensación cobra por encima de ese umbral y nuestro preconcepto de que es una profesión bien paga.

Por curiosidad, revisamos los salarios mensuales por encima de 8.000 USD. Son 20 filas. La mediana imputada queda por debajo de ese corte, de modo que esas filas no fueron rellenadas. En 18 hay al menos una tecnología. En los lenguajes predominan JavaScript, con 15 apariciones; SQL, con 13; y HTML/CSS, Python y TypeScript, con 12. A partir del stack HTML/CSS + JavaScript, se trata en su mayoría de desarrolladores web. Ese stack es compartido, y cada respuesta puede reunir varias tecnologías. Esta lectura describe la cola alta de la distribución.

El Wilcoxon, el boxplot y el conteo de tecnologías también están en el apartado «Hipótesis 1» de la notebook.

3.2. Hipótesis 2:

3.2.1. Definición de la hipótesis

La hipótesis afirma: “Los años de experiencia profesional influyen en la confianza en la precisión de las herramientas de IA”

El contraste se arma desde **df_interes**, con las transformaciones generales ya aplicadas, entre estas variables:

Variable	**Pregunta**	**No nulos**
WorkExp	QID14. Años de experiencia profesional, redondeados. Si la respuesta es 0, la consigna pide dejarla en blanco. Cuantitativa discreta.	42.893 (87,2%)
AIAcc	QID80. Cuánto confía en la precisión de la salida de las herramientas de IA en su flujo de desarrollo. Cualitativa ordinal. De mayor a menor confianza: Highly trust, Somewhat trust, Neither trust nor distrust, Somewhat distrust, Highly distrust.	33.297 (67,7%)
AISelect	QID78. Si usa herramientas de IA en su proceso de desarrollo, y	33.720 (68,5%)

Variable	Pregunta	No nulos
	con qué frecuencia. Sirve para definir la población y para imputar; después se descarta.	

Si no se respondió **AISelect**, los nulos se propagan a **AIAcc**, debido a que la primera de estas preguntas es una bifurcación. Esos nulos se interpretan como desarrolladores que no utilizan IA y quedan fuera de la población del contraste.

3.2.2. Estrategia de abordaje

Hay 343 filas que usan IA y no respondieron **AIAcc**. Se intenta mapear tendencias entre el uso de IA y su confianza con aquellos que sí respondieron; El desglose es 221 de uso diario, 57 de uso semanal y 65 de uso mensual o infrecuente.

En el apartado «Hipótesis 2» de la notebook, la matriz de contingencia cruza **AISelect** con **AIAcc** solo entre quienes respondieron la confianza:

AISelect	Highly trust	Somewhat trust	Neither trust nor distrust	Somewhat distrust	Highly distrust
Uso diario	850	6.887	3.772	3.027	1.126
Uso semanal	74	1.664	1.446	1.957	760
Uso mensual o infrecuente	56	749	895	1.721	1.142

En el uso diario, la categoría más frecuente es ‘Somewhat trust’. En el uso semanal y en el mensual o infrecuente no hay una tendencia clara. A partir de eso:

- Uso diario sin **AIAcc**: se imputan 221 nulos con Somewhat trust.
- Uso semanal o mensual sin **AIAcc**: se excluyen 122 filas. Quedan fuera por ser menos del 1% de las muestras de interés y no delimitar una tendencia clara.

Después de esa transformación, **df_confianza** queda con 49.069 filas. Para el test de Levene sobre el chequeo de la homocedasticidad y el posterior de Kruskal-Wallis que

evalúa la igualdad/discrepancia de las distribuciones de la variable **WorkExp,** configurando grupos bajo la variable cualitativa **AIAcc.**
Se descartan las muestras sin **WorkExp** o sin **AIAcc**. La tabla anterior no exigía valores sobre **WorkExp**; pero en el desarrollo del test sí, y por eso hay una reducción a 30.938 en total.

Se mantienen las cinco categorías y se compara la distribución de **WorkExp** con Kruskal-Wallis, con nivel de significación 0,05.

- H0: las distribuciones de los años de experiencia son idénticas para los grupos determinados por el nivel de confianza en la IA.
- H1: al menos uno de los cinco grupos presenta una distribución diferente a los demás.

Antes del test se revisan los supuestos. **WorkExp** es cuantitativa discreta y se puede ordenar; Kruskal-Wallis trabaja con rangos. Se respeta la independencia entre muestras, ya que, cada desarrollador que respondió aporta una única muestra. H0 plantea distribuciones idénticas: el test no exige varianzas iguales, pero:
- Si hubiera homocedasticidad, un rechazo, se interpreta como una diferencia de localización.
- Si las dispersiones difieren, el rechazo indica una diferencia de distribución, no solo de mediana.

La homocedasticidad, como ya hemos mencionado,se evalúa con Levene centrado en la mediana, porque **WorkExp** es asimétrica.

El boxplot de **WorkExp** por nivel de **AIAcc** está en ese apartado. Visualmente no se aprecian diferencias marcadas entre las cajas.

Estos cálculos están en el apartado «Hipótesis 2» de la notebook

3.2.3. Resultados obtenidos y discusión

El test de Levene da un estadístico de 6,8038 y un p-valor de $1{,}807 \times 10^{-5}$. Los desvíos de WorkExp van de 10,30 años (Somewhat trust) a 10,86 años (Highly distrust); **las dispersiones difieren y un rechazo de H0 en Kruskal-Wallis se lee como diferencia de distribución. Kruskal-Wallis da H = 46,2412 y p ≈ 0: los años de experiencia no tienen la misma distribución en los cinco niveles de AIAcc y al menos un nivel concentra la experiencia de otra manera**. Las medianas quedan entre 10 y 12 años y el rango intercuartílico, entre 14 y 15. En términos reales las magnitudes son superficiales y, a fines prácticos, la diferencia no es significativa:

aparece por el tamaño de la muestra, no porque la experiencia cambie de nivel de confianza.

La experiencia no necesariamente se traduce en una mayor desconfianza en la IA debido a un criterio ya formado por el desarrollador, sino que, en los roles entry, es posible que se hagan más preguntas de lo normal antes de implementar una sugerencia de la IA, para comprender el concepto que hay detrás de una función declarada, la importación de una librería en específico, etc.

3.3. Hipótesis 3:

3.3.1. Definición de la hipótesis

Abordamos la hipótesis de la cátedra: los niveles de satisfacción en los aspectos del trabajo actual están relacionados con la consideración de un cambio de rol o de carrera.

Con ella evaluamos si, en un empleado, la idea de cambiar de rol o de puesto se relaciona con los aspectos que más aprecia de su trabajo actual. Identificar ese patrón serviría para orientar mejoras concretas del ambiente laboral entre quienes están pensando en renunciar.

NewRole tiene cinco respuestas. Las agrupamos en dos:

- Con intención de cambio (y = 1): «I have strongly considered changing my career and/or the industry I work in», «I have somewhat considered changing my career and/or the industry I work in» y «I have transitioned into a new career and/or industry voluntarily».
- Sin intención de cambio (y = 0): «I have transitioned into a new career and/or industry involuntarily» y «I have neither consider or transitioned into a new career or industry».

El modelo intenta predecir ese grupo a partir de los rangos **JobSatPoints_***. Planteamos:

- H0: los niveles de satisfacción no tienen relación con la probabilidad de considerar un cambio de rol o de carrera ($\beta_1 = \beta_2 = \ldots = \beta_{14} = 0$).

- H1: al menos un aspecto influye en esa probabilidad (al menos un $\beta_j \neq 0$).

JobSatPoints_16 («You like your manager») se excluye. Los 14 aspectos que entran al modelo son:

Variable	**Aspecto**
JobSatPoints_1	Control over the level of quality in projects
JobSatPoints_2	Autonomy and trust to manage your own tasks
JobSatPoints_3	Collaboration and support from a team
JobSatPoints_4	Expert mentors
JobSatPoints_5	Opportunities to mentor and lead junior-level coworkers
JobSatPoints_6	Developing specialized expertise
JobSatPoints_7	Solving real-world problems
JobSatPoints_8	Job stability and career growth with a single employer
JobSatPoints_9	Innovation through solving challenging and complex problems
JobSatPoints_10	Working with new technologies and tools
JobSatPoints_11	Competitive pay and benefits
JobSatPoints_13	Recognition from peers for your work
JobSatPoints_14	Recognition from leadership for your work
JobSatPoints_15	Other

3.3.2. Estrategia de abordaje

Partimos de **df_encuestas**, el CSV completo. Una fila entra si **NewRole** es una de las cinco respuestas anteriores y si los 15 rangos numéricos **JobSatPoints_*** están completos: valores de 1 a 15, sin repetir y con suma 120. **JobSatPoints_15_TEXT** no forma parte del ranking. Quedan 24.729 observaciones, aproximadamente la mitad del conjunto de datos.

Como esos 15 rangos suman siempre 120, uno queda determinado por los demás. Eliminamos **JobSatPoints_16** para evitar esa redundancia, y el modelo usa los 14 aspectos de la tabla anterior.

Separamos el 70 % para entrenamiento y el 30 % para test, con muestreo estratificado según y y **random_state** = 42. El gráfico de barras de ese apartado compara la cantidad de cada clase en los dos subconjuntos. En entrenamiento quedan 8.334 sin intención y 8.976 con intención; en test, 3.572 y 3.847.

Estandarizamos los predictores con media 0 y desviación estándar 1. El ajuste de esa escala usa solo el entrenamiento. El modelo es una regresión logística binaria con penalización L2. El hiperparámetro C, inverso de la fuerza de esa penalización, se elige por validación cruzada de 5 pliegues sobre el entrenamiento estandarizado. La grilla es {0,001; 0,01; 0,1; 1; 10; 100} y el criterio es la exactitud media. Con el C elegido medimos la exactitud en entrenamiento y en test, y revisamos la matriz de confusión del test y los coeficientes.

Estos cálculos están en el apartado «Hipótesis 3» de la notebook.

3.3.3. Resultados obtenidos y discusión

En las 24.729 filas válidas, 11.906 (48 %) no tienen intención de cambio y 12.823 (52 %) sí la tienen.

La validación cruzada elige C = 0,01, con una exactitud media de 0,5274. En el entrenamiento la exactitud es 0,533 y en el test 0,520. Las tres cifras son próximas, de modo que el modelo no muestra sobreajuste. También quedan apenas por encima de la proporción de la clase mayoritaria.

En el test, la matriz de confusión es:

	Predicho: sin intención	**Predicho: con intención**
Real: sin intención	1.182	2.390

	Predicho: sin intención	Predicho: con intención
Real: con intención	1.168	2.679

Matriz de confusión del test (n = 7.419), con C = 0,01. De las 3.572 personas sin intención, el modelo acierta 1.182 y asigna intención de cambio a 2.390. De las 3.847 con intención, acierta 2.679 y se equivoca en 1.168. Los aciertos suman 3.861, que es la exactitud 0,520.

No se confirma la hipótesis. Aceptamos H0: no hay una relación lineal útil entre los aspectos de satisfacción y la probabilidad de considerar un cambio de rol o de carrera, y descartamos la regresión logística binaria para predecir ** **NewRole ** a partir de ** **JobSatPoints_**.*

El modelo ajustado permite leer el signo de los coeficientes. Un rango cercano a 15 es una peor valoración del aspecto. El coeficiente es el cambio en el log-odds de y = 1 por cada desvío estándar de ese rango.

Variable	Coeficiente	Aspecto
JobSatPoints_1	0,0330	Control over the level of quality in projects
JobSatPoints_9	0,0281	Innovation through solving challenging and complex problems
JobSatPoints_8	0,0036	Job stability and career growth with a single employer
JobSatPoints_10	−0,0129	Working with new technologies and tools
JobSatPoints_2	−0,0146	Autonomy and trust to manage your own tasks
JobSatPoints_13	−0,0170	Recognition from peers for your work
JobSatPoints_14	−0,0195	Recognition from leadership for your work

Variable	Coeficiente	Aspecto
JobSatPoints_6	−0,0231	Developing specialized expertise
JobSatPoints_7	−0,0254	Solving real-world problems
JobSatPoints_3	−0,0256	Collaboration and support from a team
JobSatPoints_15	−0,0394	Other
JobSatPoints_11	−0,0632	Competitive pay and benefits
JobSatPoints_4	−0,0818	Expert mentors
JobSatPoints_5	−0,0876	Opportunities to mentor and lead junior-level coworkers

En **JobSatPoints_1**, **JobSatPoints_9** y **JobSatPoints_8**, una peor valoración empuja hacia la intención de cambio. En el resto, una peor valoración empuja hacia la ausencia de intención de cambio. Cuando esos tres aspectos quedan mejor rankeados, el modelo se inclina por y = 0; cuando quedan mejor rankeados los demás, se inclina por y = 1.

Esa lectura es la del modelo ajustado. La exactitud indica que no alcanza para predecir el cambio de rol. Una exploración con modelos no lineales, como ensambles u otras transformaciones de las variables, podría dar mejores resultados.

3.4. Hipótesis 4:

3.4.1. Definición de la hipótesis

Abordamos la hipótesis: «La modalidad de trabajo posee una distribución equitativa entre los distintos formatos».

Consideramos de suma utilidad analizar la modalidad de trabajo, puesto que, para profesionales y desarrolladores, permite evaluar si la demanda laboral exige necesariamente la presencialidad o la relocalización geográfica. Identificar la

prevalencia de formatos remotos o flexibles ayuda a tomar decisiones estratégicas de carrera sin la restricción de cambiar de residencia.

Por otro lado, para las empresas u organizaciones, permite calibrar la oferta laboral frente a las tendencias del mercado. Si no existe una dominancia clara de la presencialidad, adoptar esquemas puramente remotos o de alta flexibilidad permite reducir sustancialmente costos operativos fijos (alquiler de infraestructura, mantenimiento, servicios de limpieza y equipamiento de oficinas), ampliando a su vez el acceso a un pool de talento global.

La variable del contraste es **RemoteWork** (QID24): la situación actual de trabajo, remota, híbrida o presencial. Usamos las cinco categorías, sin agrupar.

3.4.2. Estrategia de abordaje

Partimos de **df_interes**. Hay un 31,33 % de nulos en la variable **RemoteWork**. Para este análisis alcanza con las respuestas observadas, así que descartamos esos nulos. Podrían imputarse según la moda de la modalidad en cada tamaño de organización (**OrgSize**), pero no aplicamos esa imputación.

El gráfico de barras de ese apartado, titulado «Identificando tendencias en la modalidad de trabajo», muestra una asimetría marcada. Prevalece el trabajo puramente remoto. La alternativa «Your choice» (very flexible, you can come in when you want or just as needed) es la de menor cantidad. Esa disparidad sugiere que la modalidad no se distribuye de manera uniforme entre las cinco alternativas. Para comprobar si las diferencias son estadísticamente significativas y no producto del azar muestral, aplicamos una prueba de inferencia.

Usamos la prueba de chi-cuadrado (χ^2) de bondad de ajuste. Compara las frecuencias observadas en cada categoría con la frecuencia esperada si el 20 % de las respuestas correspondiera a cada una ($E_i = N / 5$). El nivel de significación es 0,05.

- H0: la distribución de las modalidades de trabajo en la población es equitativa (uniforme). Todas las categorías tienen la misma proporción de respuestas (20 % cada una).
- H1: la distribución no es uniforme. Al menos una categoría tiene una proporción distinta del 20 %.

Estos cálculos están en el apartado «H1: La modalidad de trabajo posee una distribución equitativa entre los distintos formatos», dentro de «HIPOTESIS - Grupo 23», de la notebook

3.4.3. Resultados obtenidos y discusión

Las frecuencias observadas, en el orden del gráfico de barras, son:

Modalidad	**Respuestas**
Remote	10.931
Hybrid (some remote, leans heavy to in-person)	6.732
Hybrid (some in-person, leans heavy to flexibility)	5.831
In-person	6.042
Your choice (very flexible, you can come in when you want or just as needed)	4.244

N = 33.780. Bajo H0, la frecuencia esperada es 6.756 en cada categoría.

El chi-cuadrado es 3.716,2176 y el p-valor impreso es $0{,}0000\times10^{0}$. Queda por debajo de 0,05.

No se confirma la hipótesis. Rechazamos H0 con un nivel de significación del 5 %: existe una tendencia no uniforme en la modalidad de trabajo, y la modalidad remota se destaca por encima de las demás.

Concluimos que esa modalidad resulta beneficiosa tanto para el desarrollador, al que se le otorga mayor flexibilidad, como para el empleador, que no tiene que solventar una gran oficina.

Sería interesante analizar esta encuesta a través de los años y ver si esta modalidad es una consecuencia de la pandemia, y también evaluar el tamaño de las organizaciones en las que trabajan estos desarrolladores remotos.

3.5. Hipótesis 5:

3.5.1. Definición de la hipótesis

Abordamos la hipótesis: «El tamaño de la organización/empleador está asociado con el uso de agentes de IA».

La expectativa es que quien trabaja solo, o en una organización chica, declare más uso de agentes: no puede sostener la estructura ni el costo de una persona dedicada a diseño, marketing u otras tareas que un agente puede cubrir.

La hipótesis es bivariada. **OrgSize** y **AIAgents** son las dos variables del contraste. **AIAgent_Uses** y **AgentUsesGeneral** podrían servir después para revisar la causa de ese uso. **AISelect** entra solo para mirar si los nulos de **AIAgents** se pueden imputar, y después se descarta.

Variable	**Pregunta**	**Uso**
OrgSize	QID16. Cuántas personas emplea la organización.	Primera variable. Ocho categorías, sin agrupar. «I don't know» queda fuera del contraste.
AIAgents	QID85. Si usa agentes de IA en el trabajo, y con qué frecuencia.	Segunda variable. La categoría de copiloto es un modo de uso, no una frecuencia.
AISelect	QID78. Si usa herramientas de IA, y con qué frecuencia.	Auxiliar para los nulos de **AIAgents**. No entra al chi-cuadrado.

3.5.2. Estrategia de abordaje

Partimos de **df_interes**, con las transformaciones generales ya aplicadas. El markdown de ese apartado también fija la población en quienes responden **MainBranch** = «I am a developer by profession» y **Employment** en «Employed» o «Independent contractor, freelancer, or self-employed», con dato en **OrgSize** y **AIAgents**. Estas celdas no aplican el filtro de profesión y empleo. El contraste se arma con **AISelect**, **AIAgents** y **OrgSize**.

Entre quienes tienen **OrgSize** en una de las ocho categorías y usan IA a diario, semanalmente o con menor frecuencia, hay 1.086 filas sin **AIAgents**. La matriz de contingencia entre **AISelect** y **AIAgents**, solo entre quienes respondieron ambas, muestra dos correspondencias claras: el uso diario de IA con el uso diario de agentes (4.233 filas) y «No, and I don't plan to» con la misma respuesta en agentes (4.822). El resto de las combinaciones no delimita una moda única.

Con eso imputamos, sobre la copia de **df_interes**, 932 nulos de uso diario de IA con «Yes, I use AI agents at work daily», y 201 nulos de «No, and I don't plan to» con esa misma respuesta de **AIAgents**.

Unificamos los nulos de **OrgSize** y las variantes de «I don't know» en una sola categoría. El gráfico de torta de ese apartado, titulado «Tamaño de la organización», incluye esa categoría. Una parte grande de los desarrolladores no declaró el tamaño o no lo conoce, y eso limita el análisis.

Para el chi-cuadrado descartamos las filas que siguen sin **AIAgents** y las de **OrgSize** desconocido. **AISelect** no entra a la tabla. Quedan 25.654 filas.

Antes del test revisamos los supuestos. Las dos variables son cualitativas y cada persona aporta una sola respuesta en cada una. La aproximación pide frecuencias esperadas de al menos 5; si alguna quedara por debajo de 1, esa categoría se agruparía. No se imputan nulos para inflar una celda. Con decenas de miles de filas, un p chico puede aparecer con una asociación débil, así que el contraste se lee también con el porcentaje de cada tamaño que declara agentes.

El nivel de significación es 0,05.

- H0: **OrgSize** y **AIAgents** son independientes. La proporción de cada categoría de **AIAgents** es la misma en todos los tamaños.
- H1: no son independientes. El perfil de **AIAgents** cambia según **OrgSize**.

La primera tabla conserva las seis respuestas de **AIAgents**. Después se agrupan en tres, porque no se ve una correspondencia directa entre el tamaño y el uso, y la respuesta negativa predomina en todos los tamaños. **Yes** reúne el uso diario, semanal y mensual. La categoría de copiloto se mantiene. **No** reúne «No, but I plan to» y «No, and I don't plan to».

Estos cálculos están en el apartado «H2: El tamaño de la organización/empleador está asociado con el uso de agentes de IA», dentro de «HIPOTESIS - Grupo 23», de Grupo23-Fund_C_Datos-StackOverflow.ipynb.

3.5.3. Resultados obtenidos y discusión

Con las seis respuestas, el chi-cuadrado es 138,6972, con 35 grados de libertad y p = $2{,}769\times10^{-14}$. La frecuencia esperada mínima es 97,2 y ninguna de las 48 celdas queda por debajo de 5.

Después de agrupar, las frecuencias son:

OrgSize	**Yes**	**Copiloto**	**No**
Just me - I am a freelancer, sole proprietor, etc.	503	158	643
Less than 20 employees	1.486	556	2.191
20 to 99 employees	1.807	671	2.672
100 to 499 employees	1.545	689	2.536
500 to 999 employees	583	259	989
1,000 to 4,999 employees	1.050	465	1.736
5,000 to 9,999 employees	402	176	686
10,000 or more employees	1.230	567	2.054

Copiloto es «No, I use AI exclusively in copilot/autocomplete mode». En total hay 8.606 Yes, 3.541 en modo copiloto y 13.507 No.

La esperada mínima de esta tabla es 174,5 y ninguna de las 24 celdas queda por debajo de 5. El chi-cuadrado es 42,6637, con 14 grados de libertad y p = $9{,}695\times10^{-5}$. N = 25.654.

Se rechaza H0 al 5 %, con las seis respuestas y también después de agruparlas: el tamaño de la organización y el uso de agentes no son independientes. La asociación es chica.

Quienes trabajan solos quedan en Yes en el 38,6 % de los casos. En las organizaciones de menos de 20 personas ese porcentaje es 35,1 %. En las de 10.000 o más, 31,9 %. Entre el freelancer y la organización grande hay unos 7 puntos. El gradiente va en la dirección esperada.

Juntar el uso diario, semanal y mensual en un solo Yes borra diferencias internas. El uso diario concentra cerca del 55 % de la variabilidad del primer test, aunque es cerca del 17 % de las respuestas. El semanal aporta menos del 4 % y el mensual cerca del 14 %. El mensual, además, no sigue la misma dirección. Por eso el estadístico baja y el p se aleja de cero, aunque el test sigue rechazando la independencia.

El gráfico de barras de quienes trabajan solos, ya con las tres categorías, no muestra un predominio del uso de agentes. No es la respuesta más frecuente: 643, frente a 503 en Yes y 158 en modo copiloto.

3.6. Hipótesis 6:

3.6.1. Definición de la hipótesis

Analizamos si es posible identificar perfiles de desarrolladores profesionales empleados o independientes según sus años de experiencia laboral (**WorkExp**), años programando (**YearsCode**) y cantidad de herramientas que utilizan en el trabajo (**ToolCountWork**) y en proyectos personales (**ToolCountPersona**l). Luego evaluamos si la distribución de la satisfacción laboral (**JobSat**) difiere entre esos perfiles. Partimos de la suposición de que a mayor cantidad de años y manejo de diferentes herramientas,

La hipótesis nula plantea que la distribución de **JobSat** es igual en los tres perfiles; la hipótesis alternativa sostiene que al menos una distribución es diferente. Esta variable de satisfacción no se utiliza para construir los perfiles, sino que se reserva para compararlos una vez formados.

3.6.2. Estrategia de abordaje

La población analizada reúne a 34.146 personas que se identificaron como desarrolladores profesionales y declararon estar empleadas o trabajar como independientes. De ellas, 17.756 tenían respuestas completas en las cuatro variables empleadas para construir los perfiles. Para comparar la satisfacción laboral se utilizaron los 17.147 casos que, además, respondieron **JobSat**. La diferencia entre estos dos números, 609 casos, no se tuvieron en cuenta para el scatter-plot con colores tipo mapa de calor dado que la cantidad de datos ya es suficientemente grande para graficar la distribución.

Como ya aclaramos en la notebook, para esta hipótesis utilizamos como dataframe base df_encuestas y no el del subconjunto df_interes. Este cambio se debe a un interés por explorar otro tipo de tratamiento de outliers. La primera celda filtra las columnas necesarias para el desarrollo.

Antes del análisis se trataron los valores extremos: **WorkExp** y **YearsCode** se limitaron a sus respectivos percentiles 99, mientras que los valores de **ToolCountWork** y **ToolCountPersonal** superiores al percentil 95 se reemplazaron por la mediana. Luego se estandarizaron las cuatro variables para que sus escalas no dominaran el análisis. El PCA resumió el 83,71 % de la varianza en sus dos primeros componentes. Para el agrupamiento con K-Means se eligieron tres clusters, comparando el método del codo y los indicadores silhouette y Davies-Bouldin.

Por último, se compararon las distribuciones de **JobSat** mediante la prueba de Kruskal-Wallis, con un nivel de significación de 0,05. Los cálculos y gráficos están en el apartado «Hipótesis 3: Perfiles de trayectoria, herramientas y satisfacción laboral» de la notebook.

3.6.3. Resultados obtenidos y discusión

La dominancia de valores altos de JobSat sobre las muestras del PCA en el scatter-plot de la fig nos hizo suponer que la distribución de esta variable tenía una asimetría positiva. El gráfico evidencia la uniformidad de valores respecto a esta variable, siendo imposible identificar perfiles de satisfacción disímiles. Comprobamos la asimetría con un gráfico de barras fig.

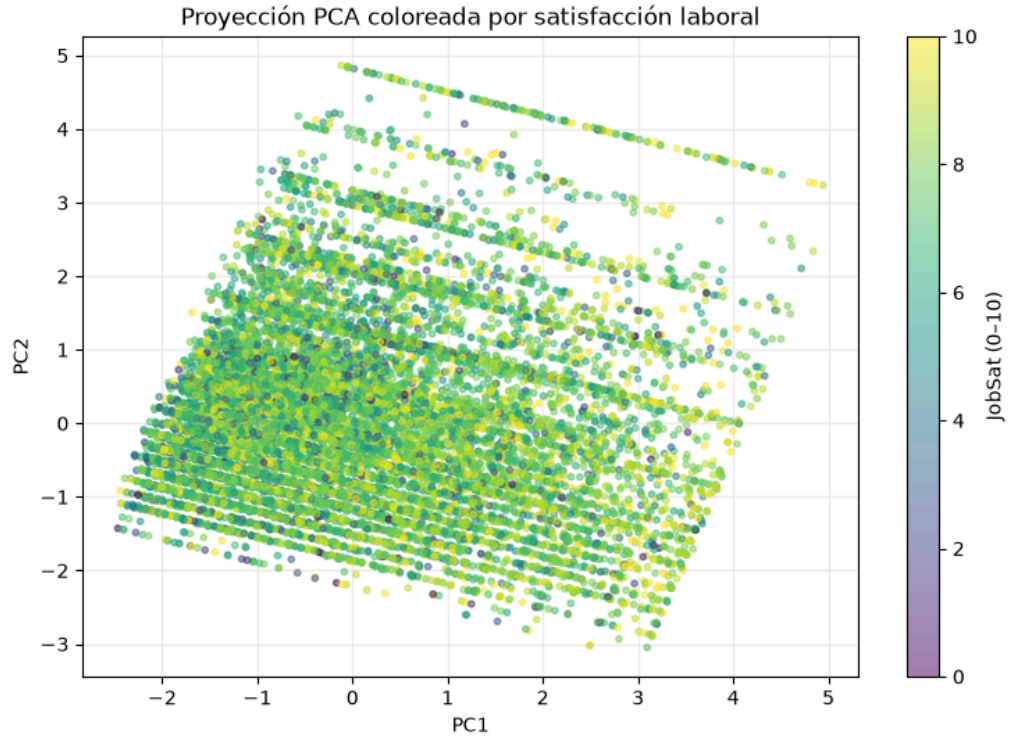


Figura 1 Scatter-plot de variables sintéticas, PC1 y PC2, coloreado por los valores de la variable JobSat. Se puede observar una clara mayoría de valores igual o superiores a 6 de JobSat

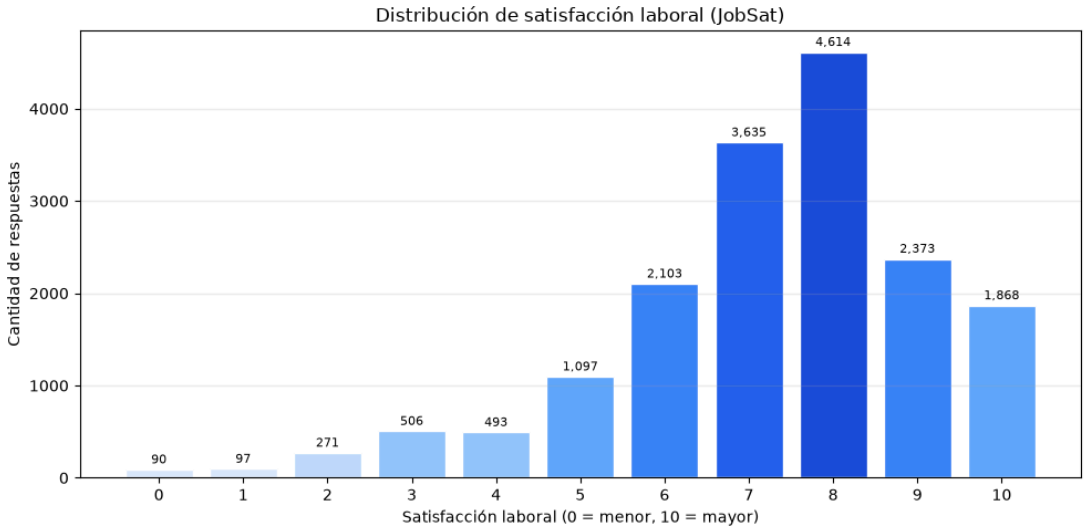


Figura 2 Distribución en barras de la variable JobSat. Muestra un asímetria positiva (hacia derecha) con la moda en 8.

Continuamos de forma exploratoria con un clustering de K-Means (fig). Se asignó 4.634 respuestas al cluster 0 (26,1 %), 3.277 al cluster 1 (18,5 %) y 9.845 al cluster 2 (55,4

%). Según las medianas de las variables originales, el cluster 0 presenta la trayectoria más extensa: 25 años de experiencia laboral y 30 años programando. El cluster 1 tiene la mayor cantidad mediana de herramientas declaradas, 15 en el trabajo y 10 en proyectos personales. El cluster 2 reúne las medianas más bajas de experiencia y años programando, 7 y 12 respectivamente, y de herramientas, 5 en el trabajo y 4 en proyectos personales.

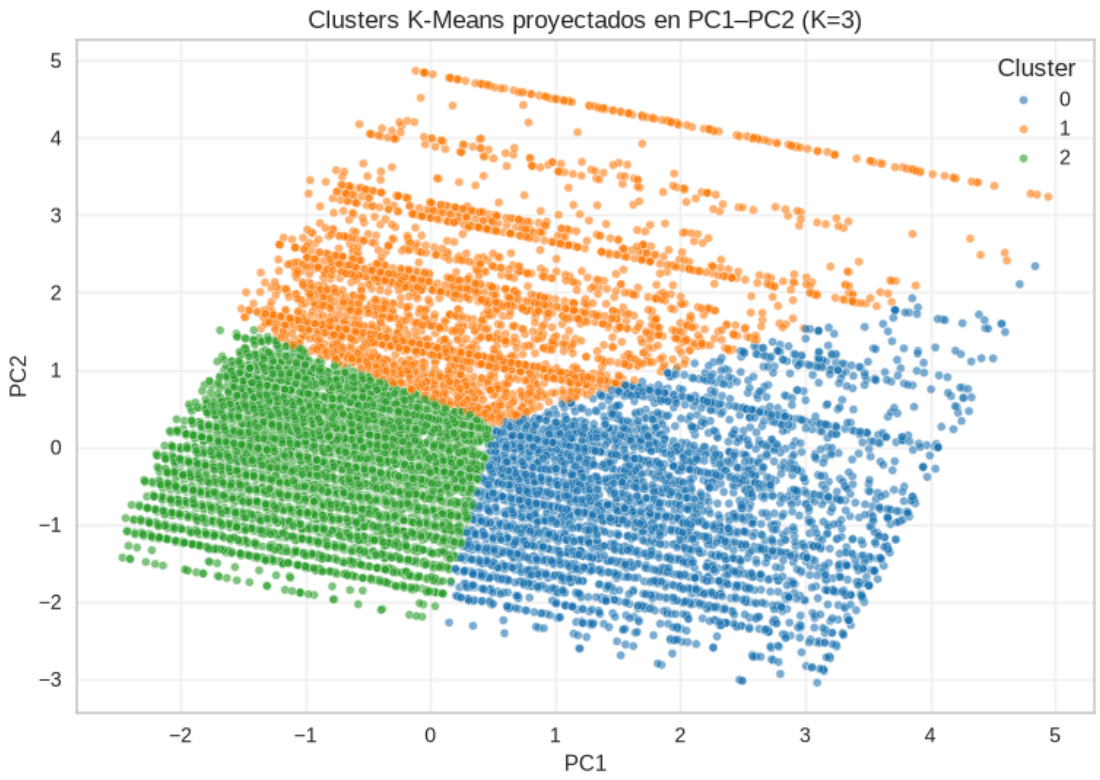


Figura 3 Scatter-plot con las mismas muestras de la figura 1, esta vez coloreadas según el cluster al que pertenecen. La división en el centro del gráfico es totalmente arbitraria, superponiendose muestras entre los límites de cada grupo.

La prueba de Kruskal-Wallis para la distribución de la satisfacción de cada grupo produjo un estadístico de $H = 157,4140$ y un p-valor de $6,57618 \times 10^{-35}$. Si analizaramos este resultado de forma aislada, como el p-valor es menor que 0,05, rechazariamos la hipótesis nula de distribuciones iguales: hay evidencia de que la satisfacción laboral difiere entre al menos dos de los perfiles. Sin embargo, al tener un visión integral del flujo, la distribución uniforme de la satisfacción en las muestras de la fig y el clustering tan arbitrario del K-Means, nos obligan a ignorar este último p-valor y nos inclinamos a aceptar la hipótesis nula.

Aquí demostramos la importancia de tener en cuenta múltiples dimensionalidades estadísticas e índices a la hora de sacar conclusiones de hipótesis sobre los datos. En

este aspecto, tomar un solo camino pero introducir sesgos desde la perspectiva del analista.

4. Conclusiones

La introducción se preguntaba hasta qué punto la experiencia profesional determina la confianza frente a las respuestas de la inteligencia artificial. Antes de mirar los datos, la expectativa del grupo era que más años de trayectoria implicarán más escepticismo al usar estas herramientas. El contraste de la hipótesis 2 encuentra diferencias estadísticamente significativas entre las distribuciones de años de experiencia de los cinco niveles de confianza, pero la distancia práctica es chica. Dentro de cada nivel se observan trayectorias muy parecidas: las medianas quedan entre 10 y 12 años y los desvíos, entre 10,30 y 10,86. Con una muestra de este tamaño, un p-valor pequeño no alcanza para tratar los años de experiencia como determinantes de la confianza o de la desconfianza.

En la hipótesis 1, la mediana del salario mensual declarado por quienes respondieron desde Argentina se ubica por encima de la cota de tres salarios mínimos, vitales y móviles. El resultado describe a ese conjunto de respuestas y abre comparaciones del poder adquisitivo del sector con el de otros rubros, con otras fuentes y en otros trabajos.

En la hipótesis 4 la distribución de la modalidad de trabajo no es uniforme y la modalidad remota se destaca sobre las demás. Leemos ese resultado como un arreglo conveniente para las dos partes. El empleador se ahorra costos operativos, de mantenimiento, de limpieza y de espacio físico, y el desarrollador gana comodidad y flexibilidad al trabajar desde su casa. La encuesta no permite evaluar un posible aspecto negativo de esa flexibilidad: su efecto sobre la productividad, por ejemplo en los tiempos de entrega o en las horas activas.

También esperábamos que quien trabaja solo recurriera con más frecuencia a los agentes de inteligencia artificial, para cubrir tareas que no puede sostener con una persona dedicada. La hipótesis 5 rechaza la independencia entre el tamaño de la organización y el uso de agentes, y el gradiente va en esa dirección, aunque la diferencia es chica: declara uso el 38,6 % de quienes trabajan solos y el 31,9 % de quienes están en organizaciones de 10.000 personas o más. Entre los freelancers, además, el uso no predomina. La respuesta más frecuente es no usar agentes (643 casos), por delante de quienes sí los usan (503) y de quienes se limitan al modo copiloto (158).

Cerrar el análisis en una sola edición deja fuera el movimiento de estos fenómenos. Consideramos más fructífero leer la encuesta a lo largo de sus ediciones, para seguir la incorporación de la inteligencia artificial, las modalidades de trabajo y las

tecnologías. En el material de la Developer Survey 2026 reunido en ***ASSETS/ACTUALIZACIONES_2026/*** ya se ve ese tipo de cambio. El trabajo freelance o por cuenta propia pasa de 3,9 % a 10,5 %. Los lenguajes más usados para trabajar con inteligencia artificial repiten el ranking general: Python, 39 %; JavaScript, 38 %; HTML/CSS, 33 %; SQL y TypeScript, 30 %; Bash/Shell, 29 %. Entre quienes tienen más de 16 años de experiencia, SQL lidera con 63 % y JavaScript sigue con 62 %; entre quienes empiezan con ayuda de inteligencia artificial, JavaScript baja al segundo lugar y SQL queda primero por un punto.

5. Referencias

1. Stack Exchange, Inc. (2025). Stack Overflow Developer Survey 2025: Results, Schema and Methodology. Repositorio oficial en GitHub. Disponible en: https://github.com/StackExchange/Survey
2. Stack Overflow. (2025). 2025 Stack Overflow Developer Survey Official Report. Disponible en: https://survey.stackoverflow.co/2025/
3. Qualtrics, LLC. (2025). 2025 Developer Survey Tool (Questionnaire form & screening specifications). Vista de impresión oficial de Qualtrics.
4. Aslam, A. (2025). Stack Overflow Developer Survey 2025 (Mirror Dataset). Kaggle Datasets. Disponible en: https://www.kaggle.com/datasets/aliaslam25/stack-overflow-developer-survey-2025
5. Consejo del Salario - Ministerio de Capital Humano de la Nación Argentina. (2025). Evolución del Salario Mínimo, Vital y Móvil (SMVM). Normativa y montos vigentes al 1 de septiembre de 2025 ($383.000 ARS). Disponible en: https://www.argentina.gob.ar/trabajo/consejodelsalario
6. Bolsas y Mercados Argentinos (BYMA). (2025). Índice Dólar BYMA Histórico: Series y cotizaciones oficiales de tipo de cambio. Disponible en: https://www.byma.com.ar/productos/productos-de-datos/indice-dolar-byma-historico